

개정 버전 : 2026.01.03



ADsP

완벽대비 요약노트

이 자료의 내용은 아답터교육의 소중한 자산이며, 특정 단체나 커뮤니티, 학원에서의 허가 받지 않은 사용 및 공유 시 법적 처벌을 받을 수 있습니다.

- ADsP 과목 및 내용

데이터 이해	데이터의 이해	데이터와 정보
		데이터베이스의 정의와 특징
		데이터베이스 활용
	데이터의 가치와 미래	빅데이터의 이해
		빅데이터의 가치와 영향
		비즈니스 모델
		위기 요인과 통제 방안
		미래의 빅데이터
	가치 창조를 위한 데이터 사이언스와 전략 인사이트	빅데이터분석과 전략 인사이트
		전략 인사이트 도출을 위한 필요 역량
		빅데이터 그리고 데이터 사이언스의 미래
데이터분석 기획	데이터분석 기획의 이해	분석 기획 방향성 도출
		분석 방법론
		분석 과제 발굴
		분석 프로젝트 관리 방안
	분석 마스터 플랜	마스터 플랜 수립
		분석 거버넌스 체계 수립
데이터분석	R기초와 데이터 마트	R기초
		데이터 마트
		결측값 처리와 이상값 검색
	통계분석	통계학 개론
		기초 통계분석
		다변량 분석
		시계열 예측
	정형 데이터 마이닝	데이터 마이닝 개요
		분류분석(Classification)
		군집분석(Clustering)
		연관분석(Association Analysis)

1과목 - 데이터 이해

1. 데이터의 이해

- 데이터와 정보

● 데이터의 정의

- 데이터 : 있는 그대로의 객관적 사실, 가공되지 않은 상태 (주문수량)
- 정보 : 데이터로부터 **가공**된 자료 (베스트셀러)
- ※ 데이터는 현실을 그대로 반영하는 '**존재적 특성**'과 맥락 속 의미부여 가능한 '**당위적 특성**'을 가짐

● DIKW 피라미드

- (1) 데이터(Data) : 가공 전의 객관적인 사실 (A대리점 핸드폰 100만원, B대리점 핸드폰 200만원)
- (2) 정보(Information) : 데이터를 통해 **패턴** 인식 (A대리점이 핸드폰이 싸다)
- (3) 지식(Knowledge) : 패턴을 통해 **의사결정** 활용 (A에서 핸드폰을 사면 이득을 보겠다)
- (4) 지혜(Wisdom) : **창의적**인 전략 (A대리점의 다른 기기들도 B대리점보다 저렴 할 것이다)

● 데이터의 유형

- (1) 형태에 따른 분류
 - 정형 데이터 : 행과 열로 구성된 구조화 (관계형DB, 엑셀-스프레드시트, CSV)
 - **반정형 데이터** : 데이터를 설명하는 **메타데이터**를 포함 (HTML, XML, JSON, RDF)
 - 비정형 데이터 : 구조화되지 않은 자유로운 형태 (SNS, 유튜브, 음원)
- (2) 표현 방식에 따른 분류
 - 정량적 데이터 : 수치로 측정된 데이터 - 수치, 기호 (온도, 풍속)
 - 정성적 데이터 : 자료의 특징을 풀어 설명 - 언어, 문자 (기상특보, 주관식 설문 응답)
- (3) 분석 목적에 따른 분류
 - 수치형 : 연속형(키, 온도), 이산형(고객 수, 판매 건수)
 - 범주형 : 명목형(성별, 혈액형), 순서형(학점, 만족도 등급)

● 암묵지, 형식지간 상호작용

- 암묵지 : 개인에게 습득되고 겉으로 드러나지 않음
 - 형식지 : 문서, 매뉴얼 등의 형상화된 지식
 - 1) **공통화** : 암묵지 지식을 다른 사람에게 알려줌
 - 2) **표출화** : 암묵지 지식을 매뉴얼이나 문서로 전환
 - 3) **연결화** : 교재, 매뉴얼에 새로운 지식 추가
 - 4) **내면화** : 만들어진 교재, 매뉴얼에서 다른 사람의 암묵지를 터득
- ☞ '**공표연내**'

- 데이터베이스의 정의와 특징

● 데이터베이스의 특징

(1) 대표적인 4가지 특징

- 공용 데이터 : 여러 사용자가 **다른 목적으로** 데이터 **공동 이용**
- 통합된 데이터 : 동일한 데이터 **중복되어 있지 않음**
- 저장된 데이터 : 저장매체에 저장
- 변화되는 데이터 : 새로운 데이터 추가, 수정, 삭제에도 현재의 정확한 데이터 유지 (**무결성**)

☞ '공통저번'

(2) 다양한 관점의 가치

- 정보 축적 및 전달 측면(**기계가독성, 검색가독성, 원격조작성**), 정보 이용 측면, 정보 관리 측면, 정보기술 발전 측면, 경제/산업 측면

● 데이터베이스 설계 절차

(1) 요구조건 분석

(2) **개념적** 설계 : 개념적 스키마 생성

(3) **논리적** 설계 : 개념적 ERD를 활용한 논리적 모델링

(4) **물리적** 설계 : 저장 구조 설계

☞ '개논물'

● 데이터베이스 시스템

(1) DBMS : DB를 관리, 접근 환경 제공하는 소프트웨어

- 관계형 DBMS : 테이블(표)로 정리 (MySQL, MariaDB, Oracle)
- **NoSQL DBMS** : **비정형 데이터**를 저장 및 처리 (HBase, MongoDB, CouchDB, Redis, Cassandra)

(2) 데이터베이스 스키마 : DB의 구조와 제약조건에 관한 전반적 명세

- **메타데이터** : 데이터를 설명하는 데이터, 데이터 구조를 설명하고 검색하는데 활용
- 데이터 사전 : 메타데이터와 데이터 구조 정보를 포함하는 시스템 내 저장소
- 인스턴스 : 데이터 개체를 구성하는 속성에 대한 데이터 타입과 값
- **인덱스** : 정렬, 탐색을 위한 보조 도구

(3) SQL : 데이터베이스에 접근하도록 지원하는 국제 표준 언어

- 1) 정의언어(DDL) : CREATE, ALTER, DROP
- 2) 조작언어(DML) : SELECT, INSERT, DELETE, UPDATE
- 3) 제어언어(DCL) : GRANT, REVOKE

☞ COMMIT, ROLLBACK 등의 명령어를 포함한 TCL까지도 포함 가능

- 데이터베이스 활용

● 기업 내부 활용 데이터베이스

- OLTP : 다량의 단기 **거래**를 실시간 처리
- OLAP : 다차원 데이터를 **대화식**으로 분석

- CRM : **고객**과 관련 자료 분석하여 마케팅에 활용
- SCM : **공급망 연결** 최적화
- ERP : 기업 경영 **자원**을 효율화
- RTE : 최신 정보로 **신속한** 의사결정 지원
- BI : 기업 보유 데이터 정리, 분석하는 **리포트** 중심 도구
- BA : 통계 기반 비즈니스 통찰력
- Block Chain : **네트워크에 참여**한 모든 사용자가 정보를 분산, 저장
- KMS : 기업의 모든 **지식**을 포함

● 데이터웨어하우스(DataWareHouse, DW)

- 기업 내외부 다양한 데이터를 한 곳에 저장한 중앙 저장소
- (1) 구성요소
 - ETL(Extraction, Transform, Load) : 다양한 소스 데이터 추출, 정제, 적재
 - ODS(Operational Data Store) : 다양한 DBMS에서 추출한 데이터를 임시 저장
- (2) 특징
 - 주제지향성 : 분석목적 설정이 중요
 - 데이터 통합 : 일관화 된 형식으로 저장
 - 시계열성 : 히스토리를 가진 데이터
 - **비휘발성** : 읽기전용 - 수시로 변하지 않음

● 데이터레이크(DataLake)

- 비정형 데이터를 저장하며 하둡과 연계하여 처리
- ※ 하둡 : 여러 컴퓨터를 하나로 묶어 대용량 데이터를 처리하는 오픈 소스 빅데이터 솔루션
- HDFS : 분산형 파일 저장 시스템
- MapReduce : 분산된 데이터를 병렬로 처리

2. 데이터의 가치와 미래

- 빅데이터의 이해

● 빅데이터 출현 배경

- **클라우드 컴퓨팅**(온디맨드), **분산 처리 기술**(하둡 기반), 비정형 데이터 확산, 디지털화, 인터넷 및 모바일 기기 보급, IoT 발달

● 데이터 단위

- KB < MB < GB < TB < **PB(2⁵⁰) < EB(2⁶⁰) < ZB(2⁷⁰) < YB(2⁸⁰)** (Peta < Exa < Zetta < Yotta)

☞ **‘패지요!’**

● 빅데이터의 3V (가트너 정의)

- (1) **Volume**(규모) : 데이터 양 증가
- (2) **Variety**(다양성) : 데이터 유형 증가
- (3) **Velocity**(속도) : 데이터 생성, 처리 속도 증가

※ 그 외 5V/7V에 포함되는 요소

- Value(가치) : 숨겨진 가치 발견이 중요
- Veracity(신뢰성) : 고품질 데이터
- Validity(정확성) : 데이터의 유효성 보장
- Volatility(휘발성) : 데이터의 의미 있는 기간

● 빅데이터에 대한 비유

- 산업혁명의 석탄, 철 : 산업혁명에서의 석탄, 철 역할
- 원유 : 정보제공으로 생산성 향상
- 렌즈 : 현미경이 생물학 발전 영향, 산업 전반에 영향 (구글 Ngram Viewer)
- 플랫폼 : 공동 활용 목적으로 구축된 구조물, 씨드파티 비즈니스에 활용 (메타, 카카오톡 등)
- * 씨드파티 : 원천기술을 활용한 파생상품 만드는 회사

● 빅데이터가 만들어내는 변화

- 표본조사 → **전수조사**
- 사전처리 → **사후처리**
- 질 → **양**
- 인과관계 → **상관관계**
- ☞ **'전후양상'**

- 빅데이터의 가치와 영향

● 빅데이터 가치 산정이 어려운 이유

- 특정 데이터를 언제, 어디서, 누가 활용할지 알 수 없음
- 기존에 가치 없는 데이터도 새로운 분석기법으로 가치를 창조

- 비즈니스 모델

● 빅데이터의 주요 분석기법

- 회귀분석 : 독립변수와 종속변수 간의 관계 분석 (나이가 매출에 어떤 영향을 미치는지)
- 분류분석 : 데이터가 어떤 그룹에 속하는지 판별 (스팸메일 구분)
- 연관규칙 : 여러 요소들 간의 규칙 **상관관계** 존재 (마트에서 치킨과 맥주를 같이 사는 관계)
- **유전자 알고리즘** : **최적화** 필요한 문제의 해결책
(택배차량 어떻게 배치, 최대 시청률 얻으려면 어떤 프로그램을 어떤 시간대에 방송?)
- 기계학습 : 훈련 데이터로부터 컴퓨터가 학습하고 미래를 예측 (넷플릭스 영화 추천 시스템)

- 감정분석 : 텍스트 데이터에서 감정(긍정/부정)을 분석
- 소셜 네트워크 분석 : 사람간의 관계 (SNS상 사용자들 관계 속 영향력 높은 사람 찾기)
- 텍스트 마이닝 : 텍스트로부터 자연어처리(NLP)를 통한 숨겨진 의미 발견 (문서요약, 키워드추출)

- 위기 요인과 통제 방안

● 위기 요인과 통제방안

- (1) 사생활 침해 : SNS 올린 데이터가 사생활 침해
→ 제공사 동의에서 **사용자 책임**으로 전환
- (2) 책임 원칙 훼손 : 범죄 예측 프로그램으로 예측하여 체포하는 문제
→ **결과 기반 책임 원칙** 고수
- (3) 데이터의 오용 : 분석 결과가 항상 옳은 것은 아님
→ **알고리즘 접근 허용** 및 알고리즘 해석가능한 **알고리즘미스트** 필요
* 알고리즘미스트 : 부당하게 피해가 발생한 사람들을 **구제**하는 전문인력

● 데이터 3법

- 개인정보보호법, 정보통신망법, 신용정보법
- **가명정보**의 개념 도입(통계 작성, 연구, 공익적 기록보존 목적 하에 동의 없이 활용 가능)
- ☞ **'개정'**

● 개인정보, 가명정보, 익명정보

- (1) 개인정보 : 개인을 알아볼 수 있는 정보, 동의를 받아 활용 가능 (홍길동, 33세)
- (2) **가명정보** : **가명처리**를 통해 추가정보 없이 특정 불가 (홍OO, 30대 초반)
- (3) 익명정보 : 더 이상 개인을 알아볼 수 없는 정보, **제한 없이 자유롭게 활용** (OOO, 30대)

● 개인정보 비식별화

- (1) 가명처리 (홍길동, 35세 → 임꺽정, 30세)
- (2) 총계처리 (홍길동 170cm, 임꺽정 180cm → 평균 키 175cm)
- (3) 데이터 삭제 (주민등록번호 901111-1234567 → 90년대 생, 남자)
- (4) 데이터 범주화 (홍길동, 35세 → 홍길동, 30~40세)
- (5) 데이터 마스킹 (홍길동, 35세 → 홍OO, 35세)

- 미래의 빅데이터

● 빅데이터 활용 위한 3대 요소

- **인력**, **자원(데이터)**, **기술**
- ☞ **'인자기'**

3. 가치 창조를 위한 데이터 사이언스와 전략 인사이트

- 빅데이터분석과 전략 인사이트

● 전략 인사이트 확보 방향

- Big에 초점을 맞추지 마라 : 분석 목적에 맞는 데이터 구성과 기법이 중요
- 전략적 인사이트 확보 : 단순 분석을 넘어서 실행 가능성 고려
- 가치 기반 분석 수행 : 일차원적 분석을 넘어 가치를 창출하는 다범위 분석 요구

- 전략 인사이트 도출을 위한 필요 역량

● 데이터 사이언스

- 데이터와 관련된 모든 분야의 전문지식을 종합한 학문
- 정형/비정형 데이터를 막론하고 데이터를 분석 (총체적 접근법)

● 데이터 사이언스 핵심 구성요소

- (1) 분석(Analytics) : 수학, 확률, 머신러닝, 분석학 등
- (2) IT : 프로그래밍, 데이터 엔지니어링, 컴퓨팅 등
- (3) 비즈니스 분석 : 커뮤니케이션, 스토리텔링, 시각화 등

☞ 'AIB'

● 데이터 사이언티스트의 필요역량

- (1) **Hard Skill** : 이론적 지식(수학, 통계학, 가설검정 등), 분석 기술에 대한 숙련
 - (2) **Soft Skill** : 통찰력(창의적 사고, 호기심, 비판), 설득력(스토리텔링, 시각화), 협력(커뮤니케이션)
- ※ 가트너가 제시한 역량 : 데이터 관리, 분석 모델링, 비즈니스 분석, 소프트 스킬

☞ 하드스킬은 이과적, 소프트 스킬은 문과적인 느낌

- 빅데이터 그리고 데이터 사이언스의 미래

● 빅데이터 가치 패러다임 변화

- Digitalization → Connection → Agency

- (1) Digitalization : 아날로그 세상을 디지털로 전환
- (2) Connection : 디지털화된 정보들의 연결
- (3) Agency : 연결된 정보가 스스로 행동하는 주체

☞ 'DigitalCA메라'

2과목 - 데이터분석 기획

1. 데이터분석 기획의 이해

- 분석 기획 방향성 도출

● 분석 대상과 방법에 따른 유형

- 분석대상(What)과 방법(How)이 알려져 있는지에 따라 분류

대상 방법	Known	UnKnown
Known	최적화 (Optimization)	통찰 (Insight)
Un-Known	솔루션 (Solution)	발견 (Discovery)

☞ 네 가지 유형을 복합적으로 넘나들며 분석을 수행

● 접근 방식에 따른 유형

	과제 중심적 접근	장기적 마스터 플랜
목적	빠르게 해결	지속적 분석 원인 해결
1차 목표	Speed & Test	Accuracy & Deploy
과제유형	Quick & Win	Long Term View
접근방식	Problem Solving	Problem Definition

● 분석 기획시 고려사항

- (1) 가용 데이터 파악 : 분석의 기본이 되는 데이터 확보 및 파악
- (2) 적절한 유스케이스 탐색 : 기존에 잘 구현 되어있는 유사 시나리오 활용
- (3) 장애요소에 대한 사전계획 수립 : 장애 요인 사전 파악 및 대응 전략 마련

- 분석 방법론

● 분석 방법론의 구성요소

- 절차, 방법, 도구와 기법, 템플릿과 산출물

● 분석 모델의 유형

- (1) 계층적 프로세스 모델 : 단계(Baseline으로 관리) → 태스크 → 스텝(단기간 수행 WorkPackage)
- (2) 폭포수 모델 : 이전 단계 완료되어야 다음 단계 진행 (Top-Down)

- (3) 프로토타입 모델 : **일부분(프로토타입)**을 우선 개발하고 보완
 - (4) 나선형 모델 : 여러 개발과정 거쳐 점진적으로 완성, **위험요소** 제거 초점
 - (5) 애자일 : 짧은 개발 주기를 가지고 고객 피드백을 지속적으로 반영하여 반복적인 개발
- ☞ **계층적 프로세스 모델은 빅데이터 분석 방법론의 기반**


● KDD 분석 방법론

- 데이터 선택 → 전처리 → 변환 → 마이닝 → 평가
- 1) 데이터 선택 : 원시데이터(Raw Data)나 DB에서 필요한 데이터 선택
- 2) 전처리 : 이상값, 잡음 식별 및 데이터 가공
- 3) 변환 : 변수 선택 및 차원축소
- 4) 마이닝 : 알고리즘을 선택하여 분석 수행
- 5) 평가 : 결과에 대한 해석, 결과가 충족되지 않으면 절차를 반복 수행

● Crisp-DM 분석 방법론

- 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개
- ☞ **‘업데이트모델평가전’**
- 1) 업무 이해 : 업무 목적 파악, 상황파악, 목표 설정, 프로젝트 계획 수립
- 2) 데이터 이해 : 초기 데이터 수집, 기술 분석, EDA, 데이터 품질 확인
- 3) 데이터 준비 : 데이터 셋 선택 및 정제, 통합
- 4) 모델링 : 모델링 기법 선택, 테스트 계획 설계, **모델 작성 및 평가**
- 5) 평가 : **분석결과 평가, 모델링 과정 평가, 모델 적용성 평가**
- 6) 전개 : 전개 계획, 모니터링 및 유지보수 계획 수립, 프로젝트 종료 보고서 작성, 프로젝트 리뷰
- * 평가 → 전개에서 **위대한 실패**(업무 이해로 다시 돌아감) 발생 가능

● 빅데이터 분석 방법론



1) 분석 기획

- 비즈니스 이해 및 범위 설정 : SOW(Statement of Works) - 구조화된 프로젝트 정의서
- 프로젝트 위험계획 수립 : **회피, 전이, 완화, 수용**

☞ '회전완수'

2) 데이터 준비

- 데이터 스토어 설계 : 정형, 비정형, 반정형 데이터에 따른 효율적 저장소를 설계

3) 데이터 분석

- **탐색적 데이터 분석(EDA)** : 기초 통계량 및 시각화를 통해 데이터 특성 파악
- 모델링 : 분류, 회귀, 군집 등 알고리즘 적용

- 분석 과제 발굴

● 분석과제 명세

- 분석과제 정의서 : 분석 계획서 수립을 위한 핵심 입력 자료
- 분석 활용 시나리오 : 분석 결과를 어떻게 적용할지 구체적으로 정의한 실행 중심 문서

● 하향식 접근 방법

- 문제가 주어지고 해답을 찾기 위해 진행
- **문제탐색 → 문제정의 → 해결방안탐색 → 타당성 검토**

(1) 문제탐색

- 1) 비즈니스 모델 기반 탐색 : **업무, 제품, 고객, 규제와 감사, 지원인프라**

☞ '지원인프라 업무 중에 고객이 제품을 규제와 감사 했다.'

2) 발굴 범위 확장

- 거시적 관점 : **STEEP**(사회, 기술, 경제, 환경, 정치)
- 경쟁자 확대 관점 : 대체자, 경쟁자, 신규 진입자
- 시장의 니즈 탐색 관점 : 고객, 채널, 영향자
- 역량의 재해석 : 내부 역량, 파트너 네트워크

3) 내/외부 사례 참조

- 외부 참조 모델 기반(벤치마킹), 분석 **유스케이스(과거 유사한 사례)**

(2) 문제 정의 : 비즈니스 문제를 데이터 문제로 변환하여 정의

(3) 해결방안 탐색 : 기존 시스템 활용, 시스템 고도화, 인적 자원 확보, 아웃소싱 등

(4) 타당성 검토 : 경제적 타당성, 데이터 타당성, 기술적 타당성

● 상향식 접근 방법

- 문제 정의 자체가 어려울 때, 사물을 그대로 인식
- **프로세스 분류 → 프로세스 흐름 분석 → 분석요건 식별 → 분석요건 정의**
- 상향식 접근법의 적용 방법 : **비지도학습, 프로토타이핑 접근법**

● 혼합 접근 방법

- (1) 발산 단계 : 상향식 접근 방법으로서, 가능한 방안들을 도출
- (2) 수렴 단계 : 하향식 접근 방법으로서, 도출된 방안들을 분석
- ※ 디자인 싱킹 : 사용자 공감으로 시작해서 아이디어 발산/수렴 과정을 통해 발전하는 방식
 - 공감하기 → 문제정의 → 아이디어 도출 → 프로토타입 → 테스트

- 분석 프로젝트 관리 방안

● 분석 과제에서 고려해야할 5가지 요소

- 데이터 양, 속도, 데이터 복잡성, 분석 복잡성, 정확도/정밀도
- * 정확도(Accuracy)와 정밀도(Precision)는 Trade-Off 관계
- ☞ 여기에서의 정확도와 정밀도는 3과목의 오분류표에서의 평가지표와는 다른 개념

● 프로젝트 관리 지식 체계 10가지 영역

- 통합, 범위, 시간(일정), 원가, 품질, 인적자원, 의사소통, 리스크(위험), 조달(아웃소싱), 이해관계자
- ☞ '이범통이 의자에서 시원한 조리품을 먹었다.'

2. 분석 마스터플랜

- 마스터 플랜 수립

● IT 프로젝트의 우선순위 선정 기준

- 중장기 마스터 플랜을 수립 위하여 ISP를 활용
- (1) 전략적 중요도 : 전략적 필요성(조직의 비전, KPI), 시급성(해결 지연 시 Risk)
- (2) 실행 용이성 : 투자 용이성(예산 확보, ROI), 기술 용이성(기술 구현 난이도)

● 데이터 분석 프로젝트의 우선순위 선정 기준

- (1) 시급성 관점 : 비즈니스 효과(Return) - Value
- (2) 난이도 관점 : 투자비용 요소(Investment) - Volume, Variety, Velocity

(어려움)	1	2
난이도		
(쉬움)	3	4
	(현재)	시급성 (미래)

- 시급성 중심 전략 : 3 → 4 → 2
- 난이도 중심 전략 : 3 → 1 → 2
- ☞ 시급성이 현재에 해당한다는 것은 시급성이 높다는 의미

● 데이터 분석 로드맵

- 데이터 기반 의사결정을 조직에 정착시키기 위한 중장기 계획
- 체계 도입 단계 → 유효성 검증 단계 (**파일럿 프로젝트** 수행) → 확산 및 고도화 단계

- 분석 거버넌스 체계 수립

● 분석 거버넌스 체계 구성요소

- 조직, 프로세스, 시스템, 데이터, 분석관련 교육 및 마인드 육성체계
- ☞ **‘시조프로마인드데’**

● 데이터 분석 수준 진단

(1) 분석 준비도

분석적 업무파악	인력 및 조직	분석기법
발생한 사실 분석업무 예측분석 업무 시뮬레이션 분석업무 분석업무 정기적 개선	분석전문가 직무 존재 분석전문가 교육훈련 프로그램 관리자들의 기본적 분석능력 전사 분석업무 총괄 조직 존재 경영진 분석업무 이해능력	업무별 적합한 분석기법 사용 분석업무 도입 방법론 분석기법 라이브러리 분석기법 효과성 평가 분석기법 정기적 개선
분석 데이터	분석 문화	IT 인프라
분석업무를 위한 데이터 충분성 분석업무를 위한 데이터 신뢰성 분석업무를 위한 데이터 적시성 비구조적 데이터 관리 외부 데이터 활용 체계 마스터데이터 관리(MDM)	사실에 근거한 의사결정 관리자의 데이터 중시 회의 등에서 데이터 활용 경영진의 직관보다 데이터 데이터 공유 및 협업 문화	운영시스템 데이터 통합 EAL, ETL 등 데이터 유통체계 분석전용 서버 및 분석환경 빅데이터 분석환경 통계분석 환경 비주얼분석 환경


☞ **‘IT문데기인파’**

(2) 분석 성숙도

단계	비즈니스 부문	조직 및 역량부분	IT 부문
도입	실적 분석 및 통계 정기 보고 수행 운영 데이터 기반	일부 부서에서 수행 담당자 역량에 의존	데이터 웨어하우스 데이터 마트 ETL/EAI OLAP
활용	미래결과 예측 시뮬레이션 운영 데이터 기반	전문담당부서 수행 분석 기법 도입 관리자가 분석 수행	실시간 대시보드 통계분석 환경
확산	전사성과 실시간 분석 프로세스 혁신 3.0 분석규칙 관리 이벤트 관리	전사 모든 부서 수행 분석 COE 운영 데이터 사이언티스트 확보	빅데이터 관리 환경 시뮬레이션/최적화 비주얼 분석 분석 전용 서버
최적화	외부 환경 분석 활용 최적화 업무 적용 실시간 분석 비즈니스 모델 진화	데이터 사이언스 그룹 경영진 분석 활용 전략 연계	분석 협업 환경 분석 SandBox 프로세스 내재화 빅데이터 분석

☞ 분석 성숙도 진단은 CMMI 모형(5단계)을 기반

● 분석 수준 결과 진단



- 1) 준비형 : 데이터, 인력, 조직, 분석업무, 분석기법 적용 안되어 사전 준비 필요
- 2) 정착형 : 인력, 조직, 분석업무, 분석기법 등을 제한적으로 사용
- 3) 도입형 : 조직 및 인력 등 준비도는 높으나, 분석업무 및 기법 부족
- 4) 확산형 : 6가지 분석 구성요소가 모두 갖추고 있으며, 지속적 확산이 가능

☞ '도준정확' 4사분면부터 시계방향(역순)으로 암기

● 빅데이터 거버넌스 프레임워크

- 데이터 거버넌스 : 전사 차원에서 데이터 대해 표준화된 관리 체계 수립



● 분석 지원 인프라 방안 수립

- 확장성을 고려한 플랫폼 구조 적용 (중앙집중적 관리)
 - 1) 광의의 분석 플랫폼 : 분석 서비스 제공엔진, 분석 어플리케이션, 분석 서비스 API, 하드웨어
 - 2) 협의의 분석 플랫폼 : 데이터 처리 프레임워크, 분석엔진, 분석 라이브러리
- ☞ 광의의 분석 플랫폼은 협의의 분석 플랫폼 요소들을 포함하는 개념

● 조직 및 인력방안 수립 (DSCoE : 분석조직)

- 집중 구조 : 독립적인 전담 조직 구성 (중복 업무 가능성 존재)
- 기능 구조 : 해당 부서에서 직접 분석 (DSCoE가 없음)
- 분산 구조 : 분석 조직 인력을 현업 부서에 배치

☞ '집기분'

3과목 - 데이터분석

1. R기초와 데이터 마트

- 데이터 마트

● 데이터 마트(DM)

- 특정 주제에 맞게 데이터를 모아 놓은 **소규모 데이터 웨어하우스**
- 원천 데이터 수집 → 데이터 웨어하우스 → 데이터 마트

● 요약변수와 파생변수

- (1) 요약변수 : 수집된 정보를 종합한 변수로서 **재활용성**이 높음 (1개월간 수입)
- (2) 파생변수 : 의미를 부여한 변수, **논리적 타당성** 필요 (고객구매등급)

- 결측값 처리와 이상값 검색

● EDA (탐색적 자료 분석)

- 데이터의 의미를 찾기 위해 **통계, 시각화**를 통해 파악
 - EDA의 4가지 주제
 - 1) **전향성**의 강조 : 자료 변동에 민감하지 않음
 - 2) **잔차** 계산 : 값들이 주경향으로부터 얼마나 벗어나 있는지 확인하는 척도
 - 3) 자료변수의 **재표현** : 원래 변수를 적당한 척도로 변환
 - 4) 그래프를 통한 **현시성** : 시각화를 통하여 효율적으로 파악
- ☞ '저장재현'

● 결측값 처리

- 존재하지 않는 데이터, NULL/NA로 표시
- (1) 단순대치법
 - 1) **완전분석법** : 결측값 가지는 데이터 삭제
 - 2) **평균 대치법**
 - 비조건부 평균 대치법 : 단순 평균으로 대치
 - 조건부 평균 대치법 : 회귀분석의 결과로 대치
 - 3) **단순 확률 대치법** : 확률적으로 선택하여 대치
 - Hot-Deck : 현재 데이터 셋에서 비슷한 성향으로 대체
 - Cold-Deck : 유사한 외부 출처에서 비슷한 성향으로 대체
 - Nearest Neighbor : 바로 가까운 응답으로 대체
- (2) 다중 대치법
 - 여러 번 대치하여 종합 (대치 → 분석 → 결합)


☞ 다중 대치법은 분산 과소 추정 문제 해결이 가능

● 이상값 검색

- 극단적으로 크거나 작은 값이며, 의미 있는 데이터일 수도 있음 (키 230cm)
- 이상값을 항상 제거하는 것은 아님



(1) ESD(Extreme Studentized Deviation)

- 평균으로부터 표준편차의 3배 넘어가는 데이터는 이상값으로 판단



(2) 사분위수

- $Q1 - 1.5IQR$ 보다 작거나, $Q3 + 1.5IQR$ 보다 크면 이상값으로 판단
- 상한, 하한, 최솟값, 1~3사분위값, 최댓값 등을 표현하며, 평균값은 표현하지 않음



(3) Z-Score

- 데이터를 표준화(평균 0, 표준편차 1) 후, 일정 임계 값을 초과할 경우 이상값으로 판단

(4) DBScan

- 밀도를 이용하여 밀도가 적은 부분의 데이터를 이상값으로 판단

2. 통계분석

- 통계학 개론

● 자료의 척도 구분

(1) 질적 척도

- 명목척도 : 어느 집단에 속하는지 나타내는 자료 (대학교, 성별)
- 순서척도(서열척도) : 서열관계가 존재하는 자료 (학년, 순위)

(2) 양적 척도

- 등간척도(구간척도) : 구간 사이 간격이 의미가 있으며 덧셈과 뺄셈만 가능 (온도, 지수 등)
- 비율척도 : **절대적 기준 0**이 존재하고 사칙연산 가능, **가장 많이 수집되는 자료** (무게, 나이 등)

● 기초 확률의 이해

(1) 사건 : 여러 반복된 시행을 통해 결과로서 나타나는 표본공간의 부분 집합

(2) 표본공간 : 통계적 실험에 의하여 일어날 수 있는 모든 가능한 결과

- 예) 동전 두 개를 던질 때 표본공간 $S = \{(\text{앞}, \text{앞}), (\text{앞}, \text{뒤}), (\text{뒤}, \text{앞}), (\text{뒤}, \text{뒤})\}$

(3) 확률 : 통계적 현상의 확실함을 나타내는 척도로 수학적 확률과 통계적 확률로 구분

(4) 확률의 덧셈 정리 : 두 사건 A, B 중 하나 이상 일어날 확률

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

(5) 조건부 확률 : 특정 사건 B가 발생했을 때 A가 발생할 확률

$$P(A|B) = P(A \cap B) / P(B) \quad (\text{백신을 맞았을 때 감기에 걸릴 확률})$$

(6) **독립사건** : A, B가 서로 영향을 주지 않는 사건 ($P(A|B) = P(A)$)

$$P(A \cap B) = P(A)P(B) \quad (\text{주사위 A가 3이 나왔을 때, 주사위 B가 3이 나올 확률})$$

(7) **배반사건** : A, B가 서로 동시에 일어나지 않는 사건

$$P(A \cap B) = \emptyset \quad (\text{동전을 던졌을 때 앞면과 뒷면이 동시에 나올 확률})$$

● 기초 통계의 이해

(1) 확률변수 : 표본공간의 각 원소에 해당하는 값(확률)을 대응하는 함수

- 예) 주사위 던지는 눈의 수는 1~6까지이며, 이는 확률변수 X의 가능한 값

(2) 이산확률분포 : 0, 1, 2, 3 처럼 셀 수 있는 확률변수에 확률이 대응

- 예) 주사위 눈 X에 대한 확률분포

X	1	2	3	4	5	6
P(X)	1/6	1/6	1/6	1/6	1/6	1/6

(3) 기댓값 : 장기적으로 기대되는 평균값, 확률분포의 무게중심

(4) 분산 : 각 값이 평균에서 얼마나 떨어져 있는지를 구한 값 ($V(X) = E(X^2) - [E(X)]^2$)

(5) **이항분포** : 연속된 n번의 독립적 시행에서 각 시행 확률 p를 가질 때의 이산확률분포

$$\text{- 이항분포의 평균 : } \mu = np, \text{ 이항분포의 분산 : } \sigma^2 = np(1-p)$$

(6) **정규분포** : 자연 현상이나 통계 데이터에서 자주 나타나는 대표적인 연속확률분포 ($N(\mu, \sigma^2)$)

(7) **표준정규분포** : 정규분포 중에서도 평균이 0, 표준편차가 1인 특별한 분포

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

- 기초 통계분석

● 기초 통계량

(1) 중심경향성 측면

- 평균 : 모든 값을 더한 후 데이터 개수로 나눈 값
- 중앙값 : 데이터를 크기 순서로 나열했을 때 중간에 위치한 값
- 최빈값 : 데이터에서 가장 자주 나타나는 값

(2) 분산 정도 측면

- 범위 : 최댓값에서 최솟값을 뺀 값이며, **이상치에 민감**
- 분산 : 각 데이터가 평균과 얼마나 떨어져 있는지 나타내는 지표
- 표준편차 : 분산에 제곱근을 취한 값, 원래 단위와 같아 해석이 용이
- 사분위수(IQR) : 데이터의 상위 75%와 하위 25%의 중간 범위
- **변동계수(CV)** : 표준편차에서 평균을 나눈 백분율, 단위 다른 변수간 상대적 비교에 유용

(3) 관계 측면

1) **공분산** : 두 확률변수의 상관정도

- 공분산 = 0 : 상관이 전혀 없는 상태
- 공분산 > 0 : 양의 상관관계
- 공분산 < 0 : 음의 상관관계
- **최소, 최대값이 없어** 강약 판단 불가

2) **상관계수** : 공분산의 단위와 범위 영향을 **표준화**하여, 상관정도를 -1 ~ 1값으로 표현

- 상관계수 = 1 : 정비례 관계
- 상관계수 = 0 : 상관없음
- 상관계수 = -1 : 반비례 관계


3) 공분산과 독립성의 관계

- 두 변수가 독립이면 공분산은 0이지만, 공분산이 0이라고 두 변수가 독립이라고 할 수는 없음

● 첨도와 왜도


(1) 첨도 : 자료의 분포가 얼마나 뾰족한 지 나타내는 척도

- 첨도 = 3 : 정규 분포 형태
- ⇒ 3을 빼서 0을 기준으로 정규분포 형태를 판단하기도 함
- 값이 클수록 뾰족한 모양



(2) 왜도 : 자료 분포의 비대칭 정도 (0일 때 대칭)

- 왜도 < 0 : 최빈값 > 중앙값 > 평균값
- 왜도 > 0 : 최빈값 < 중앙값 < 평균값



☞ 평균값은 꼬리를 따라감

● Summary함수 결과의 해석

- 통계 요약 해석			1) Age 변수 - Mean, Median 등 존재 → 수치형 변수 - 25% 지점 : 21.00, 75% 지점 : 39.00 - Median < Mean → 왜도 > 0 - 결측치(NA's) 개수 : 86개
	Age	Survived	
	Min. : 0.17	0:266	2) Survived 변수 - 집단의 빈도 수 → 범주형 변수
	1st Qu.: 21.00	1:152	
	Median : 27.00		
	Mean : 30.27		
	3rd Qu.: 39.00		
	Max. : 76.00		
	NA's : 86		

● 추론통계

- 일부 표본의 데이터를 바탕으로 모집단을 추정하거나 가설을 검정하는 통계 기법
- 모집단 → 표본추출 → 표본집단 → 모집단 예측(추정, 가설검정)

● 표본추출 방법

- (1) 랜덤 추출법 : 무작위로 표본 추출
- (2) 계통 추출법 : 번호 부여하여 일정 간격으로 추출
- (3) 집락 추출법 (=군집 추출법)
 - 여러 군집으로 나눈 뒤 군집을 선택하여 랜덤 추출
 - 군집 내 이질적 특징, 군집 간 동질적 특징
- (4) 층화 추출법
 - 군집 내 동질적 특징, 군집 간 이질적 특징
 - 같은 비율로 추출 시, 비례 층화 추출법
- (5) 복원, 비복원 추출
 - 복원 추출 : 추출되었던 데이터를 다시 포함시켜 표본 추출
 - 비복원 추출 : 추출되었던 데이터는 제외하고 표본 추출

● 확률분포

- 확률 변수의 개별 값들이 가지는 확률 값의 분포

(1) 이산 확률분포

- 값을 셀 수 있는 분포, 확률질량함수로 표현
- 1) 베르누이분포 : 결과가 두 가지 중 한가지로 나타나는 베르누이시행으로 나타나는 분포
 - 예) 동전 던지기, 시험의 합격/불합격
- 2) 이항분포 : N번의 베르누이시행 중 K번 성공할 확률의 분포
 - 예) 동전을 20번 던져 앞면이 나오는 횟수
- 3) 기하분포 : 성공확률이 p인 베르누이시행에서 처음으로 성공할 때까지 시행횟수의 분포
 - 예) 동전을 던져 처음으로 앞면이 나오기까지 던진 횟수
- 4) 음이항분포 : 성공확률이 p인 베르누이시행을 r번 성공할 때까지 반복 시행횟수의 분포
 - 예) 동전을 던져 앞면이 5번 나오기까지 던진 횟수
- 5) 초기하분포 : N개 중 비복원추출로 n번 추출했을 때 원하는 결과가 k번 나올 확률의 분포
 - 예) 10개 구슬 중 4개의 구슬이 당첨 구슬일 때, 4번 뽑았을 때 당첨 구슬을 2번 뽑을 확률
- 6) 다항분포 : N번 시행에서 각 시행이 여러 개의 결과를 가질 수 있는 확률 분포
 - 예) 주사위를 20번 던져 각 면이 나오는 횟수
- 7) 포아송분포 : 단위 시간 내 발생할 수 있는 사건의 발생 횟수에 대한 분포
 - 예) 하루동안 발생하는 출생자 수, 한 시간 동안 사무실에 걸려온 전화의 수

☞ '누포항하'

(2) 연속 확률분포

- 값을 셀 수 없는 분포, 확률밀도함수로 표현
- 1) 균일분포 : 모든 값 동일한 확률
- 2) 정규분포 : 우리가 일상생활에서 흔히 보는 확률변수의 평균 분포를 근사한 분포
 - 예) 사람들의 키 혹은 IQ 점수의 분포, 시험 성적의 분포
- 3) t분포 : 정규분포와 유사하지만, 꼬리 부분이 더 두껍고 긴 분포
 - (T검정 활용) 표본이 30개 보다 작은 집단에 대한 평균 검정
- 4) 카이제곱분포 : 독립적인 정규분포를 따르는 변수들의 제곱합으로 구성된 분포
 - (카이제곱 검정 활용) 두 집단의 동질성 검정, 단일 집단의 모분산 검정
- 5) F분포 : 두 개의 서로 다른 카이제곱 분포의 비율
 - (F검정 활용) 두 집단의 분산 동질성 검정
- 6) 지수분포 : 사건 간 시간 간격 분포
- 7) 감마분포 : 지수분포의 일반화
- 8) 베타분포 : 두 모수 α, β 에 대한 0~1사이 비율 분포

● 확률분포의 기댓값

- 확률변수 X의 $f(x)$ 확률분포의 대한 기댓값($E(X)$)

- 1) 이산적 확률변수 : $E(X) = \sum xf(x)$
- 2) 연속적 확률변수 : $E(X) = \int xf(x)$

- (1) 동전을 3개 던지는 확률실험을 할 때, 확률변수 X(앞면F의 개수)의 기댓값은?
- (2) 1~12의 숫자가 표시된 원형시계에서, 확률변수 X(시계 바늘이 가르키는 시간)의 기댓값은?

(1)

$$- P(X = 0) = P(\{BBB\}) = \frac{1}{8}$$

$$- P(X = 1) = P(\{FBB, BFB, BBF\}) = \frac{3}{8}$$

$$- P(X = 2) = P(\{FFB, FBF, BFF\}) = \frac{3}{8}$$

$$- P(X = 3) = P(\{FFF\}) = \frac{1}{8}$$

$$\therefore E(X) = 0 \times \frac{1}{8} + 1 \times \frac{3}{8} + 2 \times \frac{3}{8} + 3 \times \frac{1}{8} = 1.5$$

(2)



$$\therefore E(X) = \int_0^{12} xf(x)dx = \int_0^{12} x \left(\frac{1}{12}\right) dx = 6$$

● 중심극한정리

- 임의의 모집단으로부터 추출된 표본분포는 표본크기가 충분히 크면(30개 이상) 정규분포
- 모집단의 분포에 상관없이 표본평균분포가 정규분포를 이룸

● 표본평균의 표본분포

(1) 표본평균의 기댓값: $E(\bar{X}) = \mu$

(2) 표본평균의 분산: $V(\bar{X}) = \frac{\sigma^2}{n}$

(3) 표본평균의 표준편차: $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ (=표준오차)

(4) 표본평균의 표준화: $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$

(μ : 모집단의 평균, σ : 모집단의 표준편차, $\bar{X}$: 표본평균, n : 표본의 크기)

● 점추정

- 모집단이 특정한 값으로 추정하며, 추정량(Estimator)으로 모수를 추정

(1) 추정량의 조건

- 1) 불편성(Unbiasedness) : 추정량의 기댓값이 실제 모수와 같음 (편향이 0이 되는 경우)
- 2) 효율성(Efficiency) : 여러 추정량 중 분산이 작은 것이 더 효율적인 추정량
- 3) 일치성(Consistency) : 표본 크기가 증가할수록 추정량이 모수에 가까워짐
- 4) 충족성(Sufficiency) : 추정량이 모집단의 정보를 최대한 반영

☞ '불효일총'

(2) 대표적인 추정량

1) 모집단의 평균 $\mu \rightarrow$ 표본평균 $\bar{X} = \frac{1}{n} \sum X$

2) 모집단의 분산 $\sigma^2 \rightarrow$ 표본분산 $s^2 = \frac{1}{n-1} \sum (X - \bar{X})^2$

● 구간추정

- 모집단이 특정한 구간으로 추정 (95%, 99%를 가장 많이 사용)

(1) 모집단의 분산을 알고 있는 경우

$$\bar{X} - Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

- 신뢰수준 95% : $Z_{\frac{\alpha}{2}} = 1.960$

- 신뢰수준 99% : $Z_{\frac{\alpha}{2}} = 2.576$

(2) 모집단의 분산을 모르는 경우

- 자유도가 $n-1$ 인 **t분포**를 이용하여 신뢰구간을 추정

$$\bar{X} - t_{\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}} \quad (S : \text{표본표준편차})$$

● 가설검정

- 모집단의 특성에 대한 주장을 가설로 세우고 표본조사로 가설의 채택여부를 판정

(1) 귀무가설(H_0) : 일반적으로 생각하는 가설 (차이가 없다)

(2) 대립가설(H_1) : 귀무가설을 기각하는 가설, **증명하고자 하는 가설** (차이가 있다, 크다/작다)

(3) 유의수준(α) : 귀무가설이 참일 때 기각하는 **1종 오류**를 범할 확률의 허용 한계 (일반적 0.05)

(4) 유의확률(p-value) : 귀무가설을 지지하는 정도를 나타내는 확률

검정결과 실제	검정결과	H0가 사실이라고 판정	H0가 거짓이라고 판정
	H0가 사실	옳은 결정	1종 오류(α)
H0가 거짓	2종 오류(β)	옳은 결정	

● 가설 검정 R결과 해석

1) 귀무가설 / 대립가설 설정

- '차이가 없다' 혹은 '동일하다' → 귀무가설

2) 양측 혹은 단측검정 확인

- 대립가설의 값이 '같지 않다' → 양측검정 / '값이 크다', '값이 작다' → 단측검정

3) 일표본 혹은 이표본 확인

- 하나의 모집단 → 일표본 / 두개의 모집단 → 이표본

4) 귀무가설 기각 혹은 채택

- $p\text{-value} < \text{유의수준}(\alpha)$ → 귀무가설 기각

- $p\text{-value} > \text{유의수준}(\alpha)$ → 귀무가설 채택

5) t검정인 경우 - 단일표본, 대응표본, 독립표본 확인

- 모집단에 대한 평균검정 → 단일표본

- 동일 모집단에 대한 평균비교 검정 → 대응표본

- 서로 다른 모집단에 대한 평균비교 검정 → 독립표본

● 모수 검정

- 모집단이 특정한 분포(보통 정규분포)를 따른다고 가정하고 수행하는 가설검정

※ 두 학교의 학생들의 수학 점수에 대한 t검정

```
> t.test(schoolA, schoolB, conf.level=0.95)

Welch Two Sample t-test

data: schoolA and schoolB
t = -0.59758, df = 97.409, p-value = 0.5515

alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -10.293157  5.528998

sample estimates:
mean of x      mean of y 
 61.91373     64.29581
```

- 1) 귀무가설/대립가설 설정
 - ‘차이가 없다’ 혹은 ‘동일하다’ → 귀무가설로 설정
 - : 두 학교의 성적은 동일하다
- 2) 양측 혹은 단측검정 확인
 - 대립가설의 값이 같지 않다 → 양측검정
- 3) 일표본 혹은 이표본 확인
 - 두개의 모집단 → 이표본
- 4) 귀무가설 기각 혹은 채택
 - p-value : 0.5515 > 유의수준(α) : 0.05 → 귀무가설 채택
- 5) 단일표본, 대응표본, 독립표본 확인
 - 서로 다른 모집단에 대한 평균비교 검정 → 독립표본

☞ 독립표본 t-검정은 두 집단의 분산이 같다는 가정(등분산 가정)이 전제가 되며, 등분산을 가정하지 않는 경우 Welch의 t-검정을 사용

● 비모수 검정

- 모집단에 대한 아무런 정보 없어, 관측 자료가 특정 분포를 따른다고 가정 불가 시 검정
- 두 관측 값의 순위나 차이로 검정
- 부호검정, 순위합검정, 맨-휘트니 U검정, 크루스칼-왈리스 검정, 콜모고로프-스미르노프 검정, 카이제곱 검정

☞ 카이제곱 검정은 범주형 변수간의 검정에 주로 활용되며, 적합도, 독립성, 동질성 검정에 활용

● 회귀분석

(1) 개념 : 독립변수들이 종속변수에 영향을 미치는 파악하는 분석방법

- 1) 독립변수 : 원인을 나타내는 변수 (x)
- 2) 종속변수 : 결과를 나타내는 변수 (y)
- 3) 잔차(오차) : 계산값과 예측값의 차이


☞ 회귀분석은 독립변수와 종속변수간의 상관관계를 분석하는 방법이며, 인과관계를 보장하지 않음

(2) 회귀계수 추정방법

- 최소제곱법(=최소자승법) : 잔차의 제곱합(SSE)이 최소가 되는 회귀계수와 절편을 구하는 방법

(3) 회귀모형 평가

- R-square : 총 변동 중에서 회귀모형에 의하여 설명되는 변동이 차지하는 비율 (0 ~ 1)



● SST, SSE, SSR

- (1) SST : 전체의 변동
- (2) SSE : 모형에 의해 설명되지 않는 변동
- (3) SSR : 모형에 의해 설명되는 변동
- (4) $R^2 = SSR/SST = 1 - SSE/SST$

☞ SST : Sum of Squares Total / SSR : Sum of Squares Regression / SSE : Sum of Squares Error

● 회귀분석 종류

- (1) 단순회귀 : 1 개의 독립변수와 종속변수의 선형관계
- (2) 다중회귀 : 2 개 이상의 독립변수와 종속변수의 선형관계
- (3) 다항회귀 : 2 개 이상의 독립변수와 종속변수가 2 차 함수 이상의 관계
- (4) 규제항이 포함된 회귀

- 릿지회귀(L2 규제) : L2 규제항을 포함 - $\sum W^2$
- 라쏘회귀(L1 규제) : L1 규제항을 포함 - $\sum |W|$
- 엘라스틱넷 : L1 과 L2 를 동시에 규제

(5) 교호항이 포함된 회귀 : 독립변수들의 교호작용이 포함된 회귀 모형

- * 교호작용 : 두 개 이상의 독립변수가 상호작용을 하여, 종속변수에 영향을 미치는 경우

● 선형회귀분석의 가정

- (1) 선형성 : 종속변수와 독립변수는 선형관계
- (2) 등분산성 : 오차의 분산이 고르게 분포
- (3) 정규성 : 오차가 정규분포의 특성을 지님
- (4) 독립성 : 오차가 서로 독립

☞ '선분정독'

● 다중공선성 문제

- 독립변수들간 강한 상관관계가 나타나는 문제

(1) 진단 방법

- 변수간 상관관계수 절댓값이 0.8 이상이면 의심

- VIF(분산팽창인수) 값이 10 이상이면 다중공선성 존재한다고 판단 ($VIF = \frac{1}{1-R^2}$)

- 조건수가 30 이상이면 의심

(2) 해결방안 : 독립변수 제거, 차원 축소, 변수 선택, 규제항이 포함된 회귀

● 최적의 회귀 방정식 탐색 방법

(1) 전진선택법 : 변수를 하나씩 추가하면서 최적의 회귀방정식을 찾아내는 방법

(2) 후진제거법 : 변수를 하나씩 제거하면서 최적의 회귀방정식을 찾아내는 방법

(3) 단계별 선택법 : 전진선택법 + 후진제거법으로 변수를 추가할 할 때 벌점을 고려

1) AIC (아카이케 정보 기준) : 편향과 분산이 최적화 되는 지점 탐색, 자료가 많을수록 부정확

2) BIC (베이즈 정보 기준) : AIC를 보완했지만 AIC보다 큰 패널티를 가지는 단점

3) Mallows's Cp : SSE(잔차 제곱합)을 활용한 판단

☞ AIC와 BIC 모두 작을수록 좋음

● 회귀분석의 분산분석(ANOVA)표

요인	제곱합	자유도	제곱평균	F비
회귀	$SSR = \sum(\hat{Y} - \bar{Y})^2$	p(회귀계수 수)	$MSR = \frac{SSR}{p}$	$F = \frac{MSR}{MSE}$
잔차	$SSE = \sum(Y - \hat{Y})^2$	n(전체 데이터 수) - p - 1	$MSE = \frac{SSE}{n - p - 1}$	
총	$SST = SSR + SSE$	n - 1		

- ANOVA 검정 : 3 개 이상의 그룹의 평균을 비교하는 검정 (회귀모형의 유의성 분석 시 활용)

- 전체 데이터 수 = 자유도 + 1

- 결정계수(R-Square) = SSR/SST

- 수정된 결정계수 = $1 - (n - 1)(MSE/SST)$

☞ 다중 회귀에서는 수정된 R-square 값을 일반적으로 사용

● 회귀 모형의 검정

1) 독립변수와 종속변수 설정

2) 회귀계수 값의 추정

3) 모형이 통계적으로 유의미한가 : 모형에 대한 F 통계량, p-value

- 귀무가설 : '모든 회귀계수는 0 이다'

4) 회귀계수들이 유의미한가 : 회귀계수들의 t 통계량, p-value

- 각각의 회귀계수에 대한 귀무가설 : '회귀 계수는 0 이다'

5) 위 1), 2) 모두를 기각하면 해당 모델을 활용

6) 모형이 설명력을 갖는가 : 결정계수(R square) 값

※ 회귀 모형의 검정결과 해석

```
Call:
lm(formula = height ~ age + no_siblings, data = ageandheight)

Residuals:
    Min       1Q   Median       3Q      Max
-0.28029 -0.22490 -0.02219  0.14418  0.48350

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   64.95872    0.55752  116.515 1.28e-15 ***
age           0.63516    0.02254   28.180 4.34e-10 ***
no_siblings   -0.01137    0.05893   -0.193  0.851
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2693 on 9 degrees of freedom
Multiple R-squared: 0.9888, Adjusted R-squared: 0.9863,
F-statistic: 397.7 on 2 and 9 DF, p-value: 1.658e-09
```

- 종속변수 height / 독립변수 age, no_siblings
- 회귀모형 F분포의 p-value(1.658e-09)가 0.05보다 작으므로 **모형이 유의미**
- age의 p-value(4.34e-10)가 0.05보다 작으므로 **회귀계수 유의미**
- no_siblings의 p-value(0.851)가 0.05보다 크므로 제외하고 회귀분석 **재수행을 권장**
- 위 모형은 **다중회귀 모형**
- R-square : 0.9888, Adjusted R-square : 0.9863 (모형은 전체 데이터의 **98% 이상을 설명**)
- 회귀 자유도 : 2, 잔차의 자유도 : 9 → 총 2 + 9 + 1 = **12개의 데이터**를 활용하여 분석
- 모델 회귀 식 : $Y_{height} = 0.63516X_{age} - 0.01137X_{no_siblings} + 64.95872$

☞ no_siblings 변수가 유의하지 않기에, 제거하고 검정을 다시 수행하는 것은 연구자의 판단


- 다변량 분석

● 상관관계의 유형

- 두 변수간의 선형적 관계가 존재하는지 파악하는 분석

(1) 피어슨 상관분석 : 양적 척도, 연속형 변수, 선형관계 크기 측정

(2) 스피어만 상관분석 : 서열 척도, 순서형 변수, 선형/비선형적 관계 나타냄



● 주성분 분석 (PCA)

- 상관성 높은 변수들의 **선형 결합**으로 차원을 축소하여 새로운 변수를 생성
- 자료의 **분산이 가장 큰 축이 첫 번째 주성분 (고유값 고려)**
- 두번째 주성분은 첫 번째 주성분과 **직교**하면서 다음으로 분산이 큰 방향
- **70 ~ 90%의 설명력**을 갖는 수를 결정

(1) 주성분 분석의 결과 해석


```
> result<-prcomp(data,center=T,scale.=T)
> summary(result)
```

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.1119	1.0928	0.72181	0.67614	0.49524	0.27010	0.2214
Proportion of Variance	0.6372	0.1706	0.07443	0.06531	0.03504	0.01042	0.0070
Cumulative Proportion	0.6372	0.8078	0.88223	0.94754	0.98258	0.99300	1.0000

- center=T : 평균을 0, scale.=T : 데이터의 표준화 수행
 - 첫번째 주성분(PC1)의 분산(0.6372)이 가장 큼
 - 두 개의 주성분(PC1, PC2)을 적용하면 **전체 데이터의 약 80%를 설명**

(2) 스크리플롯(Screplot)

- 주성분의 개수를 선택하는데 도움이 되는 그래프 (x축 주성분 개수, y축 분산변화)
- 수평을 이루기 바로 전 단계 개수로 선택



☞ 주성분 개수의 선택은 절대적인 것은 없으며, 연구자의 판단 (3개로 선택도 가능)

● 다차원 척도법 (MDS : Multi-Dimensional Scaling)

- 데이터 간 **거리 정보**의 근접성을 보존하는 방식으로 차원 축소하여 시각화
- (1) 특징 : 데이터 축소 목적, **Stress 값**이 0에 가까울 수록 좋음, 글로벌 최적점 도달 어려움
- (2) 종류 : 계량적 MDS(**양적척도** 활용), 비계량적 MDS(**순서척도** 활용)

- 시계열 예측

● 시계열 분석

- 시간의 흐름에 따라 관찰된 자료의 특성을 파악하여 미래를 예측 (주가데이터, 기온데이터)

● 시계열 데이터의 변동 요인

- (1) 추세 요인 : 장기적으로 증가, 감소하는 추세
- (2) 계절 요인 : 계절과 같이 고정된 주기에 따라 변화
- (3) 순환 요인 : 알려지지 않은 주기를 갖고 변화 (**경제 전반, 특정 산업**)
- (4) 불규칙 요인 : 위 3가지로 설명 불가능한 요인

☞ '추운 계절의 순환이 불규칙하다.'

● 정상성

- 시계열 예측을 위해서는 **모든 시점에 일정한 평균과 분산**을 가지는 정상성을 만족해야 함
- (1) 정상시계열로 변환 방법
 - 1) **차분** : 현 시점의 자료를 이전 값으로 빼서 평균을 일정하게 만드는 방법
 - 2) 변환 : 로그변환, 제곱근변환, Box-Cox 변환 등으로 분산을 안정화

● 평활화

- 이동평균법 : 일정 기간의 평균
- 지수평활법 : 최근 시간 데이터에 가중치를 부여

● 백색 잡음

- 시계열 모형의 오차항을 의미 (평균 및 분산 일정, 자기상관 없음, **정상성 만족**)
- 평균이 0 이면 가우시안 백색잡음

● 시계열 모형

- (1) 자기회귀(AR) 모형
 - 자기자신의 과거 값이 미래를 결정하는 모형
 - 부분자기상관함수(**PACF**)를 활용하여 $p+1$ 시점부터 급격 감소하면 AR(p) 모형 선정
 - (2) 이동평균(MA) 모형
 - 이전 백색잡음들의 선형결합으로 표현되는 모형
 - 자기상관함수(**ACF**)를 활용하여 $q+1$ 시점부터 급격히 감소하면 MA(q) 모형 선정
 - (3) 자기회귀누적이동평균(ARIMA) 모형
 - AR 모형과 MA 모형의 결합
 - **ARIMA(p, d, q)**
 - 1) p 와 q 는 AR 모형과 MA 모형이 관련 있는 차수
 - 2) d 는 **정상화시에 차분 몇 번 했는지** 의미
 - 3) $d = 0$: ARMA 모델 / $p = 0$: IMA 모델 / $q = 0$: ARI 모델
- ☞ 계절성이 있는 경우 SARIMA 사용을 고려

3. 정형 데이터 마이닝

- 데이터 마이닝 개요

● 데이터 마이닝

- 방대한 데이터 속에서 새로운 **규칙, 패턴을 찾고** 예측을 수행하는 분야
- 목표 정의 → 데이터 수집 및 이해 → 데이터 전처리 → 데이터 마이닝 기법 적용 → 평가 및 해석


● 데이터 마이닝의 유형

- (1) 지도학습 : 정답이 있는 데이터를 활용
 - 분류 : 인공신경망, 로지스틱 회귀분석, 나이브베이즈, 분류트리, KNN, SVM 등
 - 회귀 : 인공신경망, 선형회귀분석, 회귀트리 등
- (2) 비지도학습 : 정답이 없는 데이터들 사이의 규칙을 파악
 - 군집분석, 연관규칙분석, 차원축소

● 과대적합과 과소적합

- (1) **과대적합** : 모델이 지나치게 데이터를 학습하여 매우 복잡해진 모델 (**높은 분산, 낮은 편향**)
- (2) **과소적합** : 데이터를 충분히 설명하지 못하는 단순한 모델 (**낮은 분산, 높은 편향**)

☞ 분산과 편향은 Trade-Off 관계



● 데이터 분할과 교차검증

- 과대적합과 과소적합을 방지하고, 데이터가 불균형한 문제를 해결하기 위해 사용

(1) 분할된 데이터 셋 종류

- 1) 훈련용(Training Set) : 모델을 학습하는데 활용
- 2) 검증용(Validation Set) : 모델의 과대,과소 적합을 **조정(튜닝)**하는데 활용
- 3) 평가용(Test Set) : **모델을 평가**하는데 활용

(2) 분할된 데이터의 학습 및 검증 방법

- 1) 홀드아웃 : 전체 데이터를 학습용과 검증용으로 한 번만 나누어 사용
- 2) K-fold 교차검증 : 데이터를 k개의 집단으로 구분하여 **k-1개 학습, 나머지 1개로 검증**
- 3) LOOCV : **1개의 데이터로만 검증** 나머지로 학습, 신뢰도가 높지만 연산량이 많음
- 4) 부트스트래핑 : 복원추출을 활용하여 데이터 셋을 생성, 데이터 부족, 불균형 문제 해소

- 분류분석

● 로지스틱 회귀분석

- 종속변수가 **범주형 데이터**를 대상으로 성공과 실패 2개의 집단을 분류하는 문제에 활용

(1) 로지스틱 회귀분석의 원리

1) 오즈(Odds)

- 성공할 확률과 실패할 확률의 비
- $Odds = P / (1 - P) = \text{성공확률} / \text{실패확률}$

2) 로짓(logit)변환

- 오즈에 자연로그(자연상수 e가 밑)를 취하여 선형 관계로 변환
- $\log_e\left(\frac{P}{1-P}\right) = wx + \beta$ ($w > 0$: 확률 증가)

3) 시그모이드 함수

- 로짓 함수의 역함수를 통하여, 0~1사이 확률을 도출하는 함수
- $P = \frac{1}{1 + e^{-(wx + \beta)}}$

(2) 로지스틱 회귀분석의 검정

- 1) 회귀계수 추정 : **최대우도법**
- 2) 모형전체 검정 : 우도비검정(카이제곱검정)

● KNN(K-Nearest Neighbors)

- 거리 기반으로 이웃에 더 많은 데이터가 포함되어 있는 범주로 분류
- 단순하고 효율적이며, 훈련이 따로 필요 없는 **Lazy Model**
- **K에 따라 결과가 달라짐**

● 나이브베이지 분류

(1) 베이즈 정리

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(A \cap B)}{P(B)} \quad (P(A|B): \text{사후확률}, P(B|A): \text{우도}, P(A): \text{사전확률}, P(B): \text{주변우도})$$

A대학 입시에 응시한 남학생과 여학생의 비율이 60%와 40%이고 남학생의 합격률은 30%, 여학생의 합격률은 50%이다. 이때, A대학에 합격한 신입생 중 남학생을 고를 확률은?

우도표	합격률	불합격률	
남학생	0.6×0.3 = 0.18	0.6×0.7 = 0.42	0.6
여학생	0.4×0.5 = 0.20	0.4×0.5 = 0.20	0.4

$$P(A|B) = P(\text{남학생} | \text{합격한 신입생}) = \frac{P(A \cap B)}{P(B)} = \frac{0.18}{0.38} = 0.47$$

☞ 과거의 경험을 활용하는 귀납적인 추론 방법

(2) 나이브베이지 분류

- **나이브(독립) + 베이즈 정리**를 기반으로 계산을 단순화하여 범주에 속할 확률 계산
- 서로 독립적이라는 가정이 필요

● 의사결정나무(Decision Tree)

- **노드 내 동질성이 커지고, 노드 간 이질성이 커지는 방향**으로 분리하는 트리 구조 모델

(1) 특징

- 화이트 박스 모델, **높은 과적합** 위험
- ※ 과적합 방지 방안
 - **정지규칙** : 분리를 더 이상 수행하지 않고 나무의 성장을 멈춤
 - **가지치기** : 일부 가지를 제거하여 과적합을 방지

(2) **노드 분할 방법**

1) 분류(범주형)에서의 분할 방법

- CHAID 알고리즘 : 카이제곱 통계량
- CART 알고리즘 : **지니지수** 활용 ($1 - \sum P^2$)
- C4.5/C5.0 알고리즘 : **엔트로피지수** 활용 ($-\sum P(\log_2 P)$)

2) 회귀(연속형)에서의 분할 방법

- CHAID 알고리즘 : ANOVA, F-통계량
- CART 알고리즘 : 분산감소량

- 지니지수와 엔트로피지수 계산



- 앞면 확률 = $\frac{3}{5}$, 뒷면 확률 = $\frac{2}{5}$

- 지니지수 : $1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = \frac{12}{25}$

- 엔트로피지수 : $-\frac{3}{5}\log_2\left(\frac{3}{5}\right) - \frac{2}{5}\log_2\left(\frac{2}{5}\right)$

● 서포트벡터머신(SVM)

- 마진이 최대가 되는 초평면을 찾아 선형이나 비선형 **이진 분류**, 회귀에서 활용 가능한 다목적 모델

(1) 구성요소

- 하이퍼플레인(초평면) : 데이터를 구분하는 기준이 되는 경계, **가중치벡터와 편향으로 결정**
- 서포트벡터 : 클래스를 나누는 하이퍼플레인과 가까운 위치의 샘플
- 마진 : 하이퍼플레인과 서포트벡터 사이의 거리
- **커널함수** : 저차원 데이터를 고차원 데이터로 변경하는 함수

(2) 유형

- 하드마진분류 : 오류 비허용
- 소프트마진분류 : 마진 내 어느 정도 오류 허용

● 앙상블

- 여러 개의 예측 모형들을 조합하는 기법

(1) 보팅(Voting) : 다수결 방식으로 최종 모델을 선택

- 하드보팅 : 예측값을 다수결 투표
- 소프트보팅 : 각 확률값의 평균으로 최종결과 사용

(2) 배깅(Bagging)

- 복원추출에 기반을 둔 **부트스트랩(Bootstrap)**을 생성하여 모델을 학습 후에 보팅으로 결합
- 복원추출을 무한히 반복할 때 특정 하나의 데이터가 선택되지 않을 확률 (OOB 활용)

$$\rightarrow \lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N = 36.8\%$$

※ **랜덤포레스트** : 배깅에 의사결정나무를 추가하는 기법

- 편향은 높지만 분산이 감소(과적합에 강함), 블랙박스 모델

(3) 부스팅(Boosting)

- **잘못된 분류 데이터**에 큰 가중치를 주는 방법, 이상치에 민감
- 종류 : AdaBoost, GBM, XGBoost(**GBM보다 빠르고 규제 포함**), Light GBM(학습속도 개선)

(4) 스택킹(Stacking)

- 각각의 모델에서 학습한 예측 결과를 메타 학습기를 활용하여 다시 학습


☞ 보팅, 배깅, 랜덤포레스트는 병렬처리가 가능하며, 부스팅은 병렬처리가 불가

● 인공지능망

(1) 퍼셉트론의 등장과 한계

- 인간의 뉴런을 모방한 단층 퍼셉트론의 등장, **XOR 문제** 해결의 불가

퍼셉트론 구조에서 출력 값 계산



- (가) 퍼셉트론의 출력 : $W_1X_1 + W_2X_2 + b = (0.6) \times (0.5) + (-2.0) \times (0.3) + (1.0) = 0.7$

가중치는 각 퍼셉트론 간의 연결 강도를 의미

(2) 다층 퍼셉트론의 등장

- 입력층과 출력층 사이에 하나 이상의 은닉층을 삽입한 구조
 - 1) 활성화함수의 사용 : 시그모이드 함수를 통한 비선형 문제 해결
 - 2) 인공지능망의 특징
 - 블랙박스 모델
 - 은닉층 수와 노드 수는 **사용자가 직접 설정하는 하이퍼파라미터**
 - 은닉층 수가 많아지면 복잡한 문제 해결 가능하지만, **과적합 위험 증가**
 - 은닉층 수가 적어지면 복잡한 패턴 학습 못해 **과소적합 가능성**

(3) 인공지능망 학습 방법

- 1) 순전파(피드포워드) : 정보가 전방으로 전달
- 2) **역전파 알고리즘** : 가중치를 수정하여 **손실함수**의 값을 줄임 (활성함수의 곱 활용)
- 3) 경사하강법
 - 경사의 내리막길로 이동하여 오차가 최소가 되는 최적의 해를 찾는 기법 (편미분 활용)
- 4) **기울기 소실 문제**
 - 다수의 은닉층에서 **시그모이드 함수 사용** 시, 학습이 제대로 되지 않는 문제

(4) 활성화함수와 손실함수

- 1) 은닉층에서의 활성화함수 : 인공지능망의 선형성을 극복
 - 시그모이드 함수 : 0 ~ 1 사이의 확률 값을 가지며, 로지스틱 회귀 분석과 유사
 - 하이퍼볼릭 탄젠트(Tanh) 함수 : **-1 ~ 1 사이 값**, 시그모이드 함수의 기울기 소실문제를 지연
 - ReLU 함수 : **기울기 소실문제를 극복**, $\max(0, x)$
- 2) 출력층에서의 활성화함수
 - 시그모이드 함수 : 이진분류 모델, 0~1 사이 확률 ($\sigma = \frac{1}{1+e^{-x}}$)
 - 소프트맥스 함수 : 다중분류 모델, 확률의 총합이 1 ($\sigma_{x_k} = \frac{e^{x_k}}{\sum e^{x_i}}$)
- 3) 손실함수 : 예측값과 실제값의 차이를 측정하는 함수
 - MSE(Mean Square Error) : 회귀 모델
 - 크로스 엔트로피(Cross-Entropy) : 분류 모델

● 분류모델 평가지표

(1) 오분류표(혼동행렬)

		실제	
		TRUE	FALSE
예측	TRUE	TRUE POSITIVE (TP)	FALSE POSITIVE (FP)
	FALSE	FALSE NEGATIVE (FN)	TRUE NEGATIVE (TN)

☞ 예측과 실재가 같으면 TRUE, 예측이 TRUE면 POSITIVE

(2) 평가지표

지표	계산식
정밀도(Precision)	$\frac{TP}{TP + FP}$
재현율(Recall)	$\frac{TP}{TP + FN}$
특이도(Specificity)	$\frac{TN}{FP + TN}$
정확도(Accuracy)	$\frac{TP + TN}{TP + FP + FN + TN}$
FP Rate (False Alarm Rate)	$\frac{FP}{FP + TN}$
F-1 Score	$2 \times \frac{Precision \cdot recall}{Precision + recall}$
F-β Score	$(1 + \beta^2) \times \frac{Precision \cdot recall}{(\beta^2 \cdot Precision) + recall}$

1) 재현율(Recall)은 민감도(Sensitivity), TP Rate, Hit Rate라고도 함

2) F-1 Score는 Precision과 Recall의 조화평균

3) Precision과 Recall은 Trade-Off 관계

4) F-β Score

- $\beta > 1$: 재현율(Recall)에 큰 비중
- $\beta < 1$: 정밀도(Precision)에 큰 비중
- $\beta = 1$: F-1 Score와 동일

(3) ROC 커브

- 가로축을 1-특이도(FPR), 세로축을 민감도(TPR)로 두어 시각화한 그래프
- 그래프 면적(AUC)은 0.5~1사이이며, 1에 가까울수록 모델의 성능이 좋다고 평가

(4) 이익도표(Lift chart)

- 임의로 나눈 각 등급별로 반응검출율, 반응률, 리프트 등의 정보를 산출하여 나타내는 도표
- 향상도 곡선 : 이익도표를 시각화한 곡선


- 군집분석

● 군집분석

- 비지도 학습으로 데이터들 간 거리나 유사성을 기준으로 군집을 나누는 분석

(1) 계층적 방법 : 데이터 간 유사성을 기준으로 군집을 형성

※ 덴드로그램



- 거리를 15에서 나누면 3개의 클러스터, 25에서 나누면 2개의 클러스터로 나눌 수 있음

(2) 비계층적 방법 : 계층적 방법 외 군집분석 기법

● 거리 측정 방식

(1) 데이터 간 거리 측정 방식

1) 연속형 변수

- 유클리디안 거리 : 두 점 사이의 직선 거리
- 맨하튼 거리 : 각 변수들의 차이의 단순 합
- 체비셰프 거리 : 변수 거리 차 중 최댓값
- 민코우스키 거리 : 유클리드, 맨하튼 거리를 일반화한 거리 ($d = [\sum |x_i - y_i|^p]^{1/p}$)
- 마할라노비스 거리 : 표준화 거리에서 변수의 상관관계를 고려
- 표준화 거리 : 변수의 스케일을 맞춘 뒤의 거리 계산

	- 유클리디안 거리 : $\sqrt{(4-1)^2 + (4-2)^2} = \sqrt{13}$ - 맨하튼 거리 : $4-1 + 4-2 = 5$ - 체비셰프 거리 : $\max(4-1 , 4-2) = 3$
--	--

2) 범주형 변수

- 잭카드 유사도 : $J = \frac{|A \cap B|}{|A \cup B|}$
- 코사인 유사도 : $\cos\theta = \frac{A \cdot B}{|A||B|}$

(2) 군집 간 거리 측정 방식

- 최단 연결법(=단일 연결법) : 군집간 가장 가까운 데이터
- 최장 연결법(=완전 연결법) : 군집간 가장 먼 데이터
- 평균 연결법 : 군집의 모든 데이터들의 평균
- 중심 연결법 : 두 군집의 중심
- 와드 연결법 : 두 군집의 **편차 제곱합**이 최소가 되는 위치

● K평균 군집화(K-means Clustering)

- 비계층적 군집화 방법으로 **거리기반**

(1) 특징

- 군집의 수 **K를 사전에 지정**
- 한번 군집에 속한 데이터는 **중심점이 변경되면 군집이 변할 수 있음**
- 이상치나 초기 중심점 설정에 민감

(2) 과정

- 1) 군집의 개수 K개 설정 (**Elbow Method를 활용** 최적의 K 설정)
- 2) 임의로 K개의 초기 중심점 설정
- 3) 데이터들을 가장 가까운 군집에 할당
- 4) 데이터의 평균으로 중심점 재설정
- 5) 중심점 위치가 변하지 않을 때까지 3), 4)번 과정 반복

(3) K-means의 변형

- K-modes : 범주형 데이터인 경우 최빈값(mode) 활용
- K-medoids : 실제 데이터의 대표 값을 중심으로 선정하여 이상치에 강건

● DBSCAN

- 비계층적 군집화 방법으로 **밀도기반**

(1) 특징

- **군집 수를 사전에 정하지 않아도 됨**
- 노이즈와 이상치에 강함
- Eps와 MinPts를 사전에 설정

● 기타 비계층적 군집분석

(1) 퍼지군집화 - 확률 기반

- 각 데이터가 특정 군집에 속할 **확률**을 각각 계산해가며 군집화

(2) EM알고리즘 - 분포 기반

- Likelihood의 기댓값을 계산하는 **E단계**와 기댓값 최대화 추정값을 계산하는 **M단계** 반복

(3) 자기조직화지도(SOM) - 그래프 기반

- **신경망을 활용**하여 차원축소를 통해 지도로 형상화하여 군집화하는 방법
- **완전연결**의 형태를 가지며, **순전파** 방식만 사용
- 각 노드가 승자가 되기 위한 **경쟁 학습**

● 군집분석의 평가지표

(1) 실루엣 계수

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (-1 \sim 1)$$


- $a(i)$: i 번째 데이터에서 자신이 속한 군집 내 다른 데이터 포인트 들과의 평균 거리
- $b(i)$: i 번째 데이터에서 가장 가까운 다른 군집 내 다른 데이터 포인트 들과의 평균 거리

(2) WCSS (Within Clusters Sum of Squares)

$$WCSS = \sum_{C_k}^n (\sum_{d_i \in C_k}^{d_m} distance(d_i, C_k)^2)$$

- C : 군집의 중심 값
- d : 클러스터 내에 있는 데이터

- **Elbow Method** : 최적의 군집 개수(K) 선택 방법



- 경사가 완만해지는 지점이 최적의 K 개수

☞ 같은 군집간에는 응집도가 높고, 다른 군집간에는 응집도가 낮아야 좋은 모델

- 연관분석

● 연관분석

- 항목들간의 조건-결과로 이루어지는 패턴을 발견하는 기법 (**장바구니 분석**)

(1) 특징

- 결과가 단순하고 분명 (IF~THEN~)
- **비목적성 분석**기법
- 품목 수가 증가할수록 **계산량이 기하급수적**으로 증가

☞ **연관 분석에 시간 개념을 추가하여 순차패턴분석을 수행**

● 연관분석의 지표

(1) **지지도** : $\frac{N(A \cap B)}{\text{전체}} = P(A \cap B)$

- A와 B 두 품목이 동시에 포함된 거래 비율

(2) **신뢰도** : $\frac{P(A \cap B)}{P(A)}$

- A 품목이 거래 될 때 B품목도 거래될 확률 (**조건부 확률**)

(3) $\text{향상도} : \frac{P(A \cap B)}{P(A)P(B)}$

- A 품목과 B 품목의 상관성

(향상도 > 1 : 양의상관관계, 향상도 = 1 : 상관없음, 향상도 < 1 : 음의상관관계)

☞ '지신향'

- 맥주를 구매할 때 치킨을 구매하는 경우에 대한 신뢰도와 향상도 계산

거래코드	품목	거래 횟수
1	맥주	10
2	치킨	20
3	햄버거	70
4	맥주, 치킨	20
5	맥주, 햄버거	30
6	치킨, 햄버거	10
7	맥주, 치킨, 햄버거	40

(1) 맥주의 구매 확률 = $(10 + 20 + 30 + 40) / 200 = 0.5$

(2) 치킨의 구매 확률 = $(20 + 20 + 10 + 40) / 200 = 0.45$

(3) 맥주와 치킨의 지지도 = $(20 + 40) / 200 = 0.3$

(4) 맥주 → 치킨의 **신뢰도** = $0.3 / 0.5 = 0.6$

(5) 맥주와 치킨의 **향상도** = $0.3 / (0.5 * 0.45) = 1.33$

- 맥주와 치킨의 향상도가 1보다 크므로 **양의 상관관계**를 가짐

● 빈발항목 도출 알고리즘

(1) Apriori 알고리즘

- 최소 지지도를 만족하는 빈발 항목을 추출하여 연관규칙분석의 연산량을 줄이는 기법

- 절차 : 빈도수 집합 탐색 → 최소 지지도 확인 → 후보 집합 생성 → 반복 탐색 → 연관규칙 도출

(2) FP-Growth 알고리즘

- Apriori 알고리즘의 반복 과정을 트리 기반으로 대체하여 연산 효율 향상